

Локальная AI-платформа для инженерной фирмы

Спецификация, архитектура, экономика и критерии принятия решения

Контекст: разработка систем и проектирование плат

Инфраструктура: 2× RTX 4090D, 48 GB VRAM (96 GB суммарно)

Июль 2026

Цель доклада

Обосновать создание on-premise AI-платформы: состав системы, ограничения, риски и ожидаемый эффект для инженерной команды.

- Назначение и границы применения
- Архитектура и обязательные компоненты
- Аппаратная конфигурация и эксплуатационные лимиты
- Экономика и план внедрения
- Критерии решения go / no-go

Полная спецификация: PLATFORM_SPECIFICATION.md

01

РЕЗЮМЕ ДЛЯ РУКОВОДСТВА

Предмет проекта

Локальная AI-платформа на собственной инфраструктуре:

- Inference крупных языковых моделей (70B и 35B MoE)
- Корпоративная база знаний (RAG) по документам фирмы
- Специализированные агенты для инженерных процессов

Исходные данные проектов (ТЗ, схемы, BOM, исходный код) обрабатываются **внутри периметра** организации.

Бизнес-проблемы и ответ системы

Проблема	Решение
Использование публичных LLM с конфиденциальными данными	Контролируемый локальный контур
Длительный поиск в даташитах и внутренних спецификациях	RAG по корпоративной базе
Высокая трудоёмкость review документов и BOM	Агенты для первичного прохода
Рост переменных затрат на API	Фиксированный CapEx, нулевая стоимость токена
Потеря проектного опыта между итерациями	Накопление lessons learned

Оценка целесообразности

Показатель	Оценка
Практическая полезность для профиля фирмы	7,5–8 из 10
Срок окупаемости оборудования	3–9 месяцев
Срок окупаемости с учётом внедрения	6–14 месяцев
Реалистичный прирост производительности	25–35% FTE
Сложность внедрения и сопровождения	Средняя–высокая

Решение оправдано при команде от 5 инженеров, наличии IP-критичных проектов и выделении 0,3–0,5 FTE на сопровождение платформы.

Бизнес-цели

- Суверенитет данных и IP
- Сокращение рутинной трудоёмкости
- Сохранение корпоративного опыта
- Предсказуемая стоимость владения

Технические цели

- Параллельный запуск 70B и 35B на 96 GB VRAM
- 4–6 одновременных пользовательских сессий
- Ответы RAG с указанием источника
- Аудит запросов и действий агентов


Целевые KPI (горизонт 6 месяцев)

KPI	Целевое значение
Доля инженеров с еженедельным использованием	$\geq 70\%$
Pass rate по eval-набору (20 задач)	$\geq 75\%$
Время ответа 35B (типовой запрос)	< 30 с
Зарегистрированные утечки данных	0
Подтверждённая экономия времени команды	≥ 15 ч/нед
Доступность inference в рабочие часы	$\geq 95\%$

02

АРХИТЕКТУРА

Логическая схема



Архитектурные принципы

1. **Разделение ролей:** inference (vLLM) отделён от логики агентов (LangGraph).
2. **Две GPU** используются как **два независимых inference-контура**, не постоянный tensor parallel.
3. **RAG обязателен** для задач, связанных с компонентами, номиналами и внутренними правилами.
4. **Доступ в интернет** — только через выделенный проxy с DLP (при включении).
5. **Финальное решение по критичным задачам** остаётся за инженером (human-in-the-loop).

03

АППАРАТНАЯ ПЛАТФОРМА

Целевая конфигурация сервера

Компонент	Спецификация
GPU	2× NVIDIA RTX 4090D, 48 GB VRAM
CPU	Workstation-класс: Threadripper / EPYC / Ryzen
Оперативная память	256 GB (минимум 128 GB)
Накопитель	4 TB NVMe (модели) + 1 TB (OC)
Блок питания	1600 W
Суммарный VRAM	96 GB

Особенности RTX 4090D 48 GB

Официальная поставка NVIDIA — **24 GB**. Конфигурация **48 GB** — модифицированная (clamshell PCB, изменённый VBIOS).

Параметр	Значение
Производительность LLM	~96–97% от RTX 4090
Охлаждение	Преимущественно blower; повышенный уровень шума
Гарантийная поддержка	Ограничена; требуется приёмочное тестирование
Критичное требование к плате	PCIe x8/x8 минимум на слотах GPU

Сравнение: 48 GB vs 24 GB (суммарно на 2 GPU)

Возможность	2×24 GB	2×48 GB
70B на одной карте	Нет	Да
70B и 35B параллельно	Нет	Да
70B Q8 / контекст 32K	Нет	Да
Модели класса 120B (Q4, TP=2)	Нет	Да

Аппаратный уровень: баланс факторов

Преимущества	Ограничения	Ключевые риски
Высокая плотность VRAM на 2 GPU	Кастомные карты — нестабильность	PCIe x4 на слотах
Параллельные модели без TP	Высокое энергопотребление	Перегрев при плохом airflow
Низкая переменная стоимость inference	Отсутствие NVLink	Некорректный VBIOS
70B без tensor parallel	Нет enterprise SLA NVIDIA	Завышенные ожидания по «96 GB в одной модели»

04

ПРОГРАММНЫЙ СТЕК

Слой inference

Компонент	Назначение	Статус
Ollama	Пилот, 2–4 недели	Старт
vLLM	Production API, concurrent load	Обязательно
SGLang	Agent workloads, prefix cache	Опционально
NVIDIA NIM	Enterprise-стек NVIDIA	Опционально

Ollama не рекомендуется как единственный production-слой при нагрузке от команды 5+ человек.

Модели

Функция	Модель	GPU
Reasoning, review документов	Llama 3.3 70B AWQ	GPU0
Агенты, код, RAG-ответы	Qwen3.6-35B-A3B	GPU1
Краткие запросы	Qwen3.5-9B	GPU1
Узкая специализация: код	Qwen3-Coder-Next	GPU1

Качество reasoning относительно облачных frontier-моделей: порядка 85–90%. По задачам с корпоративной базой — выше за счёт RAG.

RAG — корпоративная база знаний

Retrieval-Augmented Generation: перед генерацией ответа система извлекает релевантные фрагменты из внутренних документов.

Источники → сегментация → embedding → Qdrant → поиск → LLM → ответ + источник

Для hardware-профиля RAG является **обязательным** элементом. Без него возрастает риск ошибок в MPN, номиналах и параметрах компонентов.

RAG: приоритеты наполнения

Коллекция	Приоритет
Даташиты, design rules	P0
Проекты, lessons learned	P0
История BOM, требования	P1
HDL patterns, style guides	P2

Ценность базы **нарастает** при дисциплине пополнения после проектов. Без кураторства — деградация качества поиска.

Агентный контур

Агент	Модель	Функция
Design Review	70B	Первичный review ТЗ и архитектуры
BOM Intelligence	35B	Подбор и проверка компонентов
HDL / Code	35B	Генерация и правка кода, testbench
Documentation	70B / 35B	Черновики документации и traceability

Стек: LangGraph, Postgres (checkpoints), MCP (интеграции).

Интеграции (MCP)

- Файловая система, Git — P0
- BOM database — P1
- Контролируемый web search — P2

Пользовательский доступ

- Open WebUI — общий чат
- Continue.dev — IDE
- API Gateway — маршрутизация 70B / 35B

Безопасность и сетевой периметр

Контур	Меры
Сеть	VLAN; inference-хост без прямого egress
Доступ	SSO / LDAP; RBAC по проектам
Данные RAG	ACL по идентификатору проекта
Агенты	Sandbox FS; Git read-only по умолчанию
Интернет	Только через проху: whitelist, DLP, аудит

Инструкции в промпте не заменяют технические средства контроля.

05

ЭКСПЛУАТАЦИЯ

Персонал и трудозатраты

Этап	FTE	Комментарий
Пилот	0,3–0,5	Совмещение с DevOps / lead
Production	0,5–1,0	AI Platform Engineer
25+ пользователей	1,0	Выделенная роль

Требуемый профиль: Linux, Docker, Python, эксплуатация RAG/LLM. Специализация ML-исследователя не требуется.

Дополнительно: 0,1 FTE senior-инженера на кураторство design rules и eval.

Пропускная способность (96 GB VRAM)

Режим: GPU0 — 70B, GPU1 — 35B.

Режим нагрузки	Комфортный режим	Предельный
Тяжёлые сессии (70B)	2	3
Лёгкие сессии (35B)	4–5	6–8
Суммарно	4–6	8–10

Размер команды	Достаточность конфигурации
5–15 инженеров	Да
25+	Требуется очередь или второй сервер

Ограничивающий фактор — пропускная способность GPU (tok/s), не объём VRAM.

06

ЭКОНОМИКА

Затраты, год 1 (оценка)

Статья	USD
Сервер и GPU	8 000–12 000
RAM, SSD, PSU	1 000–2 000
Внедрение	3 000–8 000
Электроэнергия	600–1 500
Итого	10 000–22 000

Эффект (команда 8 чел.)

Показатель	Значение
Потенциал экономии	115–135 ч/нед
Реалистично (×0,7)	80–95 ч/нед
Breakeven	3–14 мес.
ROI за 3 года	200–400%

Сравнение: облачные API при активном использовании — 6 000–24 000 USD/год плюс риск утечки IP.

07

ВНЕДРЕНИЕ И РИСКИ

Дорожная карта (20 недель)

Фаза	Срок	Содержание
0. Решение	2 нед.	Go/no-go, закупка, назначение владельца
1. Foundation	1–4	vLLM, Open WebUI, RAG P0
2. RAG production	5–8	Pipeline, ACL, IDE-интеграция
3. Agents	9–14	LangGraph, MCP, BOM и Docs
4. Hardening	15–20	Review/HDL, security, eval $\geq 75\%$
5. Эксплуатация	Постоянно	Lessons learned, ревизия базы

Основные риски

Риск	Митигация
Отказ модифицированных GPU	Burn-in; резервный cloud fallback
Отсутствие владельца платформы	0,5 FTE; KPI внедрения
Ошибки в подборе компонентов	RAG + citation + утверждение инженером
Утечка через интернет	Proxy, DLP, режим Strict
Обход в публичные LLM	Политика; удобный локальный интерфейс
Ошибка конфигурации PCIe	Workstation-плата x8/x8

Критерии GO

- Команда от 5 инженеров
- IP-критичные проекты
- 0,3+ FTE на сопровождение
- Бюджет 10–20 тыс. USD
- Готовность к 4–6 неделям пилота

Критерии NO-GO

- Команда 1–2 человека
- Нет ресурса на RAG и внедрение
- Ожидание полной автономии проектирования
- Отсутствие Linux-эксплуатации

Сравнение стратегий

Подход	Сильные стороны	Слабые стороны
Без изменений	Нулевые затраты	Утечки IP в облако
Только облако	Быстрый старт, топ-модели	Счёт, зависимость, данные
Локальная платформа	Контроль, TCO, RAG	CapEx, операционная нагрузка
Гибрид (год 2+)	Гибкость	Сложность архитектуры

Рекомендуемая траектория: локальный контур → точечный cloud overflow для нерегулярных frontier-задач.

Заключение

Локальная AI-платформа — инфраструктурное решение, а не замена инженерной экспертизы

Оценка применимости: 8 из 10 для инженерной фирмы с конфиденциальными проектами.

Ожидаемый эффект: ускорение рутинных процессов на 25–35%, защита IP, окупаемость в горизонте 6–14 месяцев при дисциплине внедрения и сопровождения.

Следующие шаги

1. Принятие решения go/no-go по чеклисту
2. Закупка и приёмка оборудования (burn-in 48 ч)
3. Назначение владельца платформы (0,3 FTE)
4. Фаза 1: vLLM, RAG, Open WebUI — 4 недели

Материалы: PLATFORM_SPECIFICATION.md · PLATFORM_PRESENTATION.pptx